RESUMEN EJECUTIVO DE RESULTADOS

1. Objetivo y enfoque metodológico

Se construyó un modelo de clasificación para cada uno de los tres casos propuestos, aplicando **un algoritmo obligatorio por dataset**. La asignación se hizo según la naturaleza de los datos y del problema, y se confirmó con validación cruzada: en la exploración inicial, cada algoritmo fue el de mejor F1 en el dataset que se le asignó.

Dataset	Problema	Algoritmo	Justificación de la asignación
Parole (n = 675)	Reincidencia en libertad condicional	**Árbol (CART)**	Decisión judicial que debe ser explicable: el árbol da reglas auditables. Predominan variables categóricas.
Heart (n = 297)	Enfermedad coronaria	**Naive Bayes**	Data mixta (continuas + códigos clínicos) y pocos datos: estima pocos parámetros y entrega probabilidades de riesgo.
Diabetes (n = 768)	Diagnóstico de diabetes	**KNN**	Todas las variables son numéricas: la distancia entre pacientes estandarizadas tiene sentido directo.

Flujo común: partición train/test estratificada → detección de outliers → imputación → balanceo → ajuste de hiperparámetros con validación cruzada → evaluación única en test. Todo el preprocesamiento se aplicó **dentro de un Pipeline**, de modo que se ajusta solo con los datos de entrenamiento de cada fold y se evita la fuga de información (*data leakage*). En los tres casos la clase de interés es la positiva (reincide / enfermo / diabetes), por lo que se priorizan **F1, Recall (sensibilidad) y AUC** sobre el accuracy.

2. Caso Parole — Árbol de decisión (CART)

Preprocesamiento

- **Faltantes:** ninguno. **Variables categóricas** (Género, Raza, Estado, Ofensas, Crimen) codificadas con One-Hot.
- **Outliers:** 31 observaciones por IQR (5.7 % del train), casi todas en Sentencia. Se **mantienen**, porque CART divide por orden ($x \leq s$) y no se ve afectado por valores extremos.
- **Desbalance severo** (11.6 % reincide). Se compararon 6 técnicas en CV: **SMOTE obtuvo el mayor F1 (0.463)**, frente a 0.420 de Undersampling, 0.377 de SMOTE-NC y solo 0.203 sin balanceo.

Modelo y resultados

La **pre-poda** (GridSearchCV, 108 combinaciones) eligió gini con profundidad 3 (15 nodos). La **post-poda** por costo-complejidad (ccp_alpha = 0.0236) redujo el árbol a **5 nodos y 3 hojas** y además mejoró el F1 de CV de 0.463 a 0.472: un árbol más simple que generaliza mejor.

Métrica en Test (n = 135)	Accuracy	Precision (1)	Recall (1)	F1 (1)	AUC-ROC
Árbol post-podado	0.867	0.450	0.563	0.500	0.794

Interpretación. Solo dos variables explican el modelo: **Estado = Virginia** (importancia 0.59) y **Ofensas múltiples** (0.41). Las reglas son: *(1)* Virginia → bajo riesgo (5 % de reincidencia en ese nodo); *(2)* fuera de Virginia y con ofensas múltiples → alto riesgo; *(3)* fuera de Virginia sin ofensas múltiples → bajo riesgo. El modelo detecta 9 de los 16 reincidentes del test con 11 falsos positivos.

Conclusión. El AUC de 0.79 indica una capacidad discriminativa aceptable, pero con un recall de 56 % y una precisión de 45 %, el modelo **solo es adecuado como herramienta de apoyo (screening)** para la junta. Dado que un falso positivo implica negar la libertad a alguien que no reincidiría, sus predicciones no deben usarse como veredicto automático, sino dentro de una revisión humana.

3. Caso Heart — Naive Bayes (R)

Preprocesamiento

- **Faltantes:** ninguno. **Clases balanceadas** (54 % sanos / 46 % enfermos), por lo que no se aplica balanceo.
- **Tipos de variables:** sex, cp, fbs, restecg, exang, slope, ca y thal como factores (son códigos clínicos, no cantidades); age, trestbps, chol, thalach y oldpeak como numéricas. Las correlaciones entre numéricas son bajas ($|r| < 0.40$), por lo que el supuesto de independencia de Naive Bayes es razonable.
- **Outliers:** identificados con IQR y Z-Score (por ejemplo chol = 564). Se **mantienen** por ser clínicamente posibles.

Corrección del modelo y resultados

En la versión inicial, la fórmula disease ~ . con preProcess (center/scale) hacía que caret convirtiera los factores en dummies numéricas; así Naive Bayes ya no usaba las variables categóricas y el suavizado de Laplace no tenía efecto.

Se corrigió usando la **interfaz x / y sin preprocesamiento**, y los hiperparámetros (laplace, usekernel, adjust) se eligieron por **ROC** con validación cruzada de 10 folds, en vez de por accuracy.

Test (n = 89)	Accuracy	Sensibilidad	Especificidad	Kappa	Falsos negativos	AUC
Modelo inicial	0.753	0.561	0.917	0.490	18 de 41	—
Modelo corregido	**0.809**	**0.756**	0.854	**0.614**	**10 de 41**	**0.887**

Interpretación. La corrección elevó la **sensibilidad de 56 % a 76 %** (8 enfermos más detectados) a cambio de una leve baja en especificidad; con un AUC de 0.887, el modelo discrimina bien entre sanos y enfermos. Al bajar el **umbral de decisión a 0.4**, la sensibilidad sube a **80.5 %** con una especificidad de 79.2 % y solo 1 punto menos de accuracy (0.798). El umbral de 0.3 no aporta nada adicional: tiene la misma sensibilidad y menor especificidad.

Conclusión. En el contexto clínico, un falso negativo (un enfermo enviado a casa) es mucho más costoso que un falso positivo (una prueba adicional). Por ello se recomienda el modelo corregido con **umbral de 0.4** como herramienta de triaje para derivar pacientes a angiografía. Este umbral se analizó sobre test; idealmente debe confirmarse con validación cruzada.

4. Caso Diabetes — KNN

Preprocesamiento

- **Faltantes:** Insulin 48.7 %, SkinThickness 29.6 %, Pregnancies 14.5 %. Se compararon 5 imputadores dentro de un pipeline con KNN: **MICE (IterativeImputer + BayesianRidge) obtuvo el mayor F1 (0.644)**, frente a 0.643 de KNNImputer (k = 15) y 0.607 de la mediana. MICE aprovecha las correlaciones de Insulin con Glucose (r = 0.58) y de SkinThickness con BMI (r = 0.65).
- **Outliers:** 68 por IQR (11.1 %). No son ruido: el **83.3 % de los outliers multivariados son diabéticas** (frente a una prevalencia de 34.9 %). Representan casos severos reales y se **mantienen**.
- **Escalado** obligatorio (StandardScaler): Insulin llega a 846 y DiabetesPedigreeFunction a 2.42.
- **Balanceo:** sin balanceo, el recall era de solo 0.566 (F1 = 0.625). Todas las técnicas lo elevaron por encima de 0.78; las 4 mejores (SMOTE, SMOTE + Tomek, Random Under y Random Oversampling) pasaron al GridSearch como hiperparámetro.

Modelo y resultados

El GridSearchCV exploró K impares de 1 a 51, los pesos (uniform / distance), la métrica (euclidean / manhattan), la técnica de balanceo y la selección de variables (5 a 8). La configuración final es **SMOTE + Tomek, las 8 variables, K = 29, weights = uniform, distancia euclidiana**. Se prefirió frente a Random Oversampling (F1 de 0.702 contra 0.699, un empate técnico) por tener **mayor recall en CV** (0.822 frente a 0.794).

	Accuracy	Precision (1)	Recall (1)	F1 (1)	AUC-ROC
Validación cruzada (5 folds)	0.751	0.613	0.822	0.699	0.836
Test (n = 154)	**0.701**	**0.551**	**0.796**	**0.652**	**0.808**

Interpretación. El modelo **detecta al 80 % de las diabéticas** (43 de 54 en test) con un AUC de 0.81. Las métricas de CV y test son consistentes, lo que indica que no hay sobreajuste. Un K pequeño (< 7) sobreajusta; a partir de K ≈ 21 la curva se estabiliza y alcanza su óptimo en K = 29. La precisión de 0.55 implica falsos positivos, pero estos solo requieren una prueba confirmatoria de laboratorio.

Conclusión. KNN, combinado con imputación MICE y balanceo, es una **herramienta de cribado eficaz**: prioriza no dejar diabéticas sin diagnosticar, que es el error de mayor costo clínico.

5. Conclusiones generales

- **El preprocesamiento fue determinante** en los tres casos: el balanceo elevó el recall de forma decisiva en Parole y Diabetes, MICE fue la mejor imputación en Diabetes y tratar correctamente las variables categóricas mejoró la sensibilidad de Naive Bayes en 20 puntos.
- **El accuracy engaña en problemas desbalanceados:** en Parole, un modelo que predijera siempre "no reincide" acertaría el 88 % sin detectar a ningún reincidente. Por eso se priorizaron F1, Recall y AUC.
- **Los outliers se conservaron en los tres casos:** en Diabetes, incluso, concentran casos positivos, por lo que eliminarlos agravaría el desbalance.
- **Desempeño final:** Heart es el caso con mejor discriminación (AUC 0.89), seguido de Diabetes (0.81) y Parole (0.79). Parole es el más difícil: pocas variables con poder predictivo y solo 78 reincidentes.

- Los tres modelos deben usarse como **herramientas de apoyo a la decisión** (screening o triaje) y no como decisiones automáticas, especialmente en Parole por sus implicancias éticas sobre la libertad individual.